Governança e Qualidade de Dados

Laboratório Qualidade de Dados (utilizando R)

Arnaldo Vitaliano, MSc.

2017


tailored
updates
reviewed
staff
guidelines
Procedures
identified
collecting
needs
covering
collection
needed
evidence
commitment
information
responsibility
part
appraisal
place
may
clearly
relation
reinforce
fed
understanding
support
missing
changes
Completeness
service
Accountability
built-in
working
top
scrutiny
supported
regularly
body's
arrangements
right
system
results
review
levels
erroneous
Information
level
quality
data
external
Arrangements
Relevance
governance
taken
performance
standards
defined
associated
Internal
time
senior
although
recording
corporate
example
comprehensive
valid
corrective
role
updated
basis
body
ensure
well
back
requirements
complete
necessitate
meet
procedures
least
set
Act
consistently
training
charged
management
documented
Accuracy
unauthorised
agreement
Corrective
programme
acted
risk
address
used
previous
areas
reporting
Systems
possible
processes
practices
document
guidance
reported
form
delivery
necessary
overall
action
business
descriptions
critical
rigorous
extensive
Policies
provision
monitor
regular
clear
manipulation
correction
communicated
Data
practice
reinforcing
agreed
analysis
forecasting
member
periodically
timely
policy
relevant
systems
reliable
work
policies
actions
objectives
cleansing
minimum
procedure
monitoring
day
assessed
compiling
implemented

O quê faremos hoje?

- Laboratório Prático
- Objetivos:
  - Utilizar técnicas de qualidade de dados
  - Utilizar linguagem R para realizar as atividades
  - Utilizar controle de versão (git)
  - Utilizar repositório para código e documentação (github)

Quem estudou antes da aula?

Antes de começarmos

Não vamos nos aprofundar nestes assuntos

O Que é R?

- R é uma linguagem de programação com foco em análise de dados;
- Criada na Nova Zelândia, por 2 estatísticos: Ross Ihaka e Robert Gentleman;
- É uma linguagem de programação interpretada, voltada à interação dinâmica com os dados e modelos;
- É gratuito e compatível com todas as plataformas;

R – Gráficos e Estatísticas

Gráficos e estatística: gráfico de dispersão com preço contra metro quadrado por bairro, cor dos pontos de acordo com número de quartos e linha de regressão.

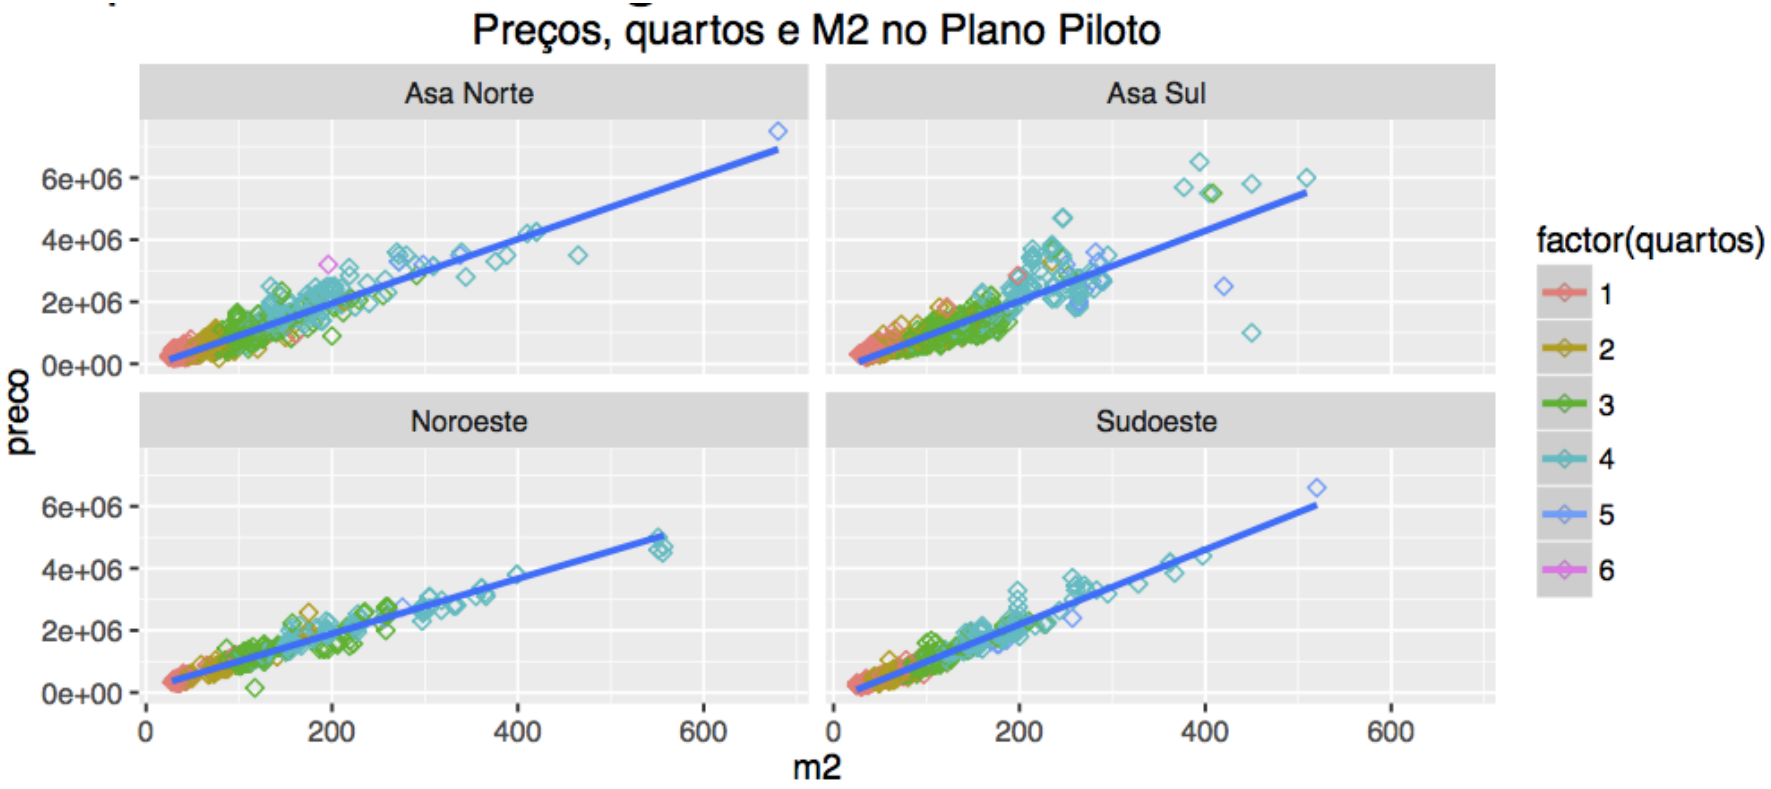

R – Gráficos e Estatísticas

Mapas e estatística: Webscraping de dados de roubos e download do mapa de Brasília no Google Maps; manipulação dos dados e construção de gráficos de calor geolocalizados.

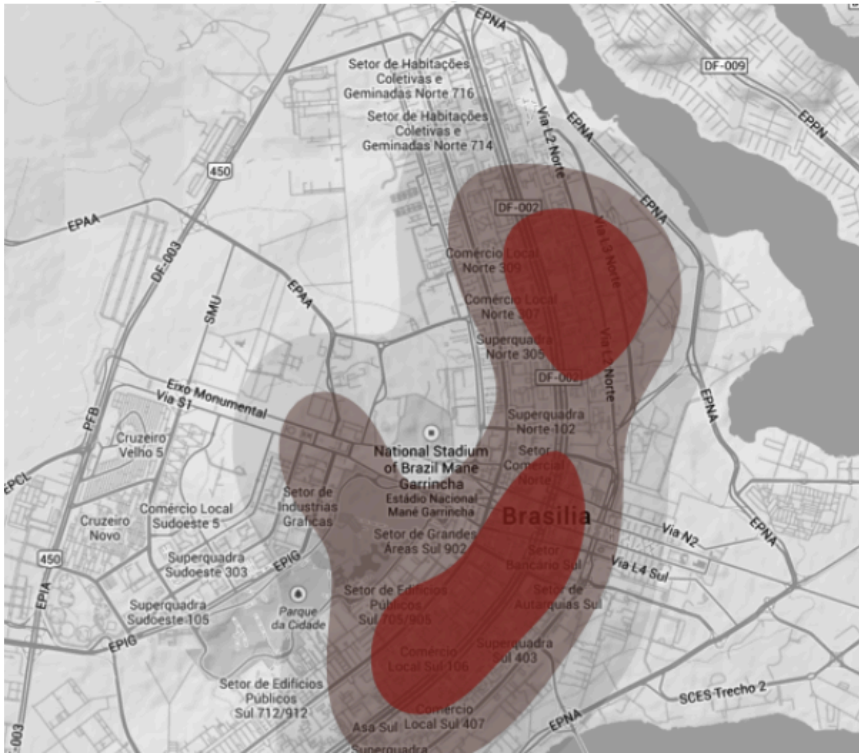

Carlos Cinelli e Edson Bastos

R – Tutorial básico

1. Abra o R Gui
2. Escreva os seguintes comandos:
   - 1 + 1
   - plot(1:10)
   - hist(rnorm(1000))
     - (repita várias vezes e veja o que acontece)

Rstudio

Apesar de o R vir com uma interface gráfica bem interessante, existe um IDE (Integrated Development Environment - Ambiente de Desenvolvimento Integrado) chamado RStudio, com várias funcionalidades e gratuito.

O RStudio tem algumas vantagens em relação ao R Gui:

- Highlight do código;
- Autocomplete;
- Match automático de parenteses e chaves;
- Interface intuitiva para objetos, gráficos, script;
- Projetos (com controle de versão);
- Interação com HTML, entre outras.

Projetos no Rstudio

Vamos criar um projeto do Rstudio para nosso laboratório. Esta é uma maneira simples de gerenciar scripts, dados e documentos relacionados ao projeto R.

- Criar projeto de Rstudio em pasta existente;
- Selecionar o nosso repositório clonado do GitHub;
- Abrir o script exemplos.R

Operações básicas

- 1 + 1 (CTRL+ENTER): roda o comando
- 3 * 4
- 2 – (4*2)/5
- 4^2 #exponencial
- 21 %/% 4 #divisão inteira
- 21 %% 4 #resto de divisão inteira

Gráficos e plotagem

- 1:10
- plot(1:10)
- rnorm(10) #números na distribuição normal
- hist(rnorm(1000) #histograma

Operadores básicos

- Atribuição:
- x <- 100 #atribui o valor 100 à variável x
- y <- 23 #atribui o valor 23 à variável y

- x + y
- x * y
- x / y

Vetores

- Concatenação
- vetor <- c(1, 4, 5, 10, 2, x, y) #concatena os valores e atribui à variável “vetor”
- Vetores são sempre de um único tipo de dados
  - Números
  - Inteiros
  - Texto
  - Números complexos
  - Lógicos (booleanos)

Vetores

- numero <- c(546.90, 10, 789)
- inteiro <- c(1L, 98L) # note o L
- complexo <- c(20i, 2+9i) # note o i
- texto <- c("meu", "vetor", "com", "varias", "palavras")
  # note as aspas
- logico <- c(TRUE, FALSE, TRUE) # sempre maiúsculo

Classe dos Vetores

- Classe dos vetores
  - numero
  - inteiro
  - complexo
  - texto
  - logico

Conversão de classe

- as.character(numero)

- # TRUE -> 1, FALSE -> 0
- as.numeric(logico)

- # Não faz sentido
- as.numeric(texto)

- # Faz sentido
- as.numeric("129873")

Estrutura

- str(x)
- str(y)
- str(vetor)
- str(numero)
- str(inteiro)
- str(complexo)
- str(texto)
- str(logico)

Tamanho

- length(x)
- length(y)
- length(vetor)
- length(texto)

Funções matemáticas

- x <- c(1, 3, -5, 10)
- abs(x) # valor absoluto
- exp(x) # exponencial em e
- sqrt(x) # raiz quadrada
- factorial(3) # fatorial
-
- choose(20,2) # análise combinatória

Funções matemáticas

- mean(x) #media
- sum(x) #somatoria
- prod(x) #produtória
- cumsum(x) #somatório cumulado
- cumprod(x) # produtório cumulado

Funções matemáticas

- var(x) # variância
- sd(x) # desvio padrão
- median(x) # mediana
- min(x) # mínimo
- max(x) # máximo

Operadores lógicos

- 1 == 0 # igual
- 1 != 0 # diferente
- 1 > 0   # maior que
- 1 < 0   # menor que
- ! 1 < 0 # negação
- TRUE & FALSE # operador AND
- TRUE | FALSE # operador OR

Exercício

- Rode o seguinte código:

- **set.seed(1)**
- **horas_trabalhadas <- rnorm(1000, 8, 0.5)**
- **valor_por_hora <- rnorm(1000, 30, 2)**

Exercício

1. Veja a estrutura dos vetores. Qual sua classe?
2. Quantas observações cada vetor tem?
3. Quais os valores máximos e mínimos?
4. Crie um vetor com o valor recebido por dia. Encontre o mínimo e o máximo.
5. Qual o valor total recebido no período?

Exercício - Solução

- str(horas_trabalhadas); str(valor_por_hora)
- class(horas_trabalhadas); class(valor_por_hora)
- length(horas_trabalhadas); length(valor_por_hora)
- min(horas_trabalhadas); min(valor_por_hora)
- max(horas_trabalhadas); max(valor_por_hora)
- valor_recebido_dia <- horas_trabalhadas * valor_por_hora
- sum(valor_recebido_dia)

Diretório de trabalho

- Toda vez que você abre uma sessão do R, ele realizará operações de leitura e gravação de dados no diretório de trabalho.

- *# qual é o diretório de trabalho atual?*
  # no seu computador o resultado vai ser diferente
  getwd() *# get working directory*
  [1] "C:/"

- A qualquer momento você pode alterar o diretório de trabalho com setwd().
- **setwd**("D:/Curso de R") ; **getwd**()

Diretório de Trabalho

- Note que o separador é o contrário do que se usa no windows, pois a barra \ é um comando especial. Uma opção, caso você queira usar o padrão do windows, é usar duas barras.
- **setwd**("C:\\diretorio1\\diretorio2")
  Existe, ainda, uma função de conveniência que cria o caminho do arquivo para você a file.path()

- **file.path**("C:", "diretorio1", "diretorio2", "arquivo.csv")
- ## [1] "C:/diretorio1/diretorio2/arquivo.csv"

Arquivos CSV

Uma das formas mais convenientes de importar e exportar dados pelo R e por meio de arquivos .csv. O csv é um formato entendido por virtualmente quase todo software. Existe uma série de funções (derivadas da read.table) que fazem este trabalho, veja mais em ? read.table. Argumentos que necessitam atenção especial:

- dec: determina o símbolo utilizado para decimal. No Brasil, utilizamos “,” mas em muitos outros lugares o padrão é “.”
- sep: como os dados estão separados? Por tab (\t), por vírgula (,), por ponto e vírgula (;), por espaço (" “)?
- fileEncoding: o padrão do R, em geral, é trabalhar com caracteres ASCII. No Brasil, são comuns os padrões latin1 ou UTF-8. Ler o arquivo com o padrão errado pode resultar em caracteres “estranhos”.

Arquivos CSV

Para ilustrar como salvar um csv, vamos utilizar a função write.csv2(). Ela e igual à write.csv() mas já tem como padrão sep = ";" e dec = ",", que são comuns no Brasil.

- **mtcars**
- **write.csv2**(mtcars, "mtcars.csv")

Arquivos CSV

Para ilustrar como ler um csv, vamos utilizar a função read.csv(), colocando os parâmetros corretos para leitura:

- carros <- **read.csv**("mtcars.csv", dec = ",", sep = ";")
- Neste caso poderíamos ter lido também com read.csv2() que já teria os parâmetros desejados.

Data Frames

Data Frames são estruturas da linguagem R muito parecidas com tabelas relacionais.

- Data frames possuem colunas com nomes
- Cada coluna tem um único tipo (classe)
- Podemos aplicar várias funções para manipular dados de data frames, como agrupar, filtrar, selecionar, somar, etc.

Data Frames

Carregando o data frame que utilizaremos no laboratório (censo):

- censo <- read.csv2("data/Censo.csv", stringAsFactor = FALSE)
- str(censo) #estrutura do data frame
- names(censo) #nomes das colunas do data frame
- View(censo) #visualizar o data frame

Data Frames

Acessar colunas do data frame

- censo[3] #pelo índice da coluna
- censo$Nome #pelo nome da coluna
- censo["Nome"] #outra maneira de acesso pelo nome
- censo[c(2,3)] #várias colunas ao mesmo tempo
- censo[c("Nome","CPF")]

Data Frames

Selecionando coluna para realizar análise:

- altura <- censo$Altura.cm #joga a coluna Altura para um vetor
- summary(altura) #verifica estatísticas básicas
- media.altura <- mean(altura) #média
- desvio.altura <- sd(altura) #desvio padrão
- altura > media.altura + 4*desvio.altura # valores que são maiores que média + 4*desvios
- gigantes <- altura[altura > media.altura + 4*desvio.altura]
- gigantes
- # [1] 270 268 267 262 266 267 251 263 266 263 256 253 259 254 256 270 269 257

Data Frames

Adicionando colunas ao data frame

- Dataframe$novacoluna <- valores
- Exercício:
- Incluir a coluna IMC no data frame do censo
- Fórmula:
  - IMC = PESO (em KG) / ALTURA^2 (em M)

Data Frames

Adicionando colunas ao data frame

- Dataframe$novacoluna <- valores
- Exercício:
- Incluir a coluna IMC no data frame do censo
- Fórmula:
  - IMC = PESO (em KG) / ALTURA^2 (em M)

- Solução: censo$IMC<- censo$Peso.kg / (censo$Altura.cm/100)^2
- summary(censo$IMC)

```
# Min.   1st Qu.  Median    Mean 3rd Qu.    Max.
#  5.421  23.650  26.260  26.820  29.320 475.000
```

Removendo colunas do data frame

- Dataframe$coluna <- NULL

- Exemplo:
- censo$IMC <- NULL
- censo$IMC

Funções de Data Frames

Funções para manipulação de data frames

- head(censo) #mostra as primeiras linhas
- tail(censo) #mostra as últimas linhas
- Subset
  - censo[1,] #primeira linha, todas colunas
  - censo[1, 1] #primeira linha, primeira coluna
  - censo[, 3] #todas linhas, terceira coluna
  - censo[1:10, c(3,4,5)] #primeiras 10 linhas, e colunas 3,4,5
  - censo[, c("Nome", "CPF", "Sexo")] #colunas nomeadas
- unique(censo$Sexo)

Biblioteca dplyr

Fornece meios de utilizar funções de data frames de maneira similar à linguagem SQL

- **filter**: filtra um data.frame com vetores lógicos. Por exemplo, filtrar valores de Salario menores ou maiores do que determinado nível.
  select: seleciona uma ou mais colunas de um data.frame. Por exemplo, selecionar a coluna de idade.
- **mutate**: cria uma nova coluna. Por exemplo, criar a coluna IMC.
  arrange: orderna o data.frame com base em uma coluna. Por exemplo, ordernar do maior ao menor Salario.
- **group_by**: agrupa um data.frame por índices. Por exemplo, agrupar os dados do censo por Categoria e número de AnosEstudo.
- **summarise**: geralmente utilizado após o group_by. Calcula valores por grupo. Por exemplo, tirar a média ou mediana do Salario, depois de agrupar por categoria e anos de estudo.

Biblioteca dplyr

- O dplyr vem também com o *pipe operator* **%>%** do pacote magritrr. Basicamente, o operador faz com que você possa escrever **x %>% f()** ao invés de **f(x)**.
- Na prática, isso tem uma grande utilidade: você vai poder escrever o código de manipulação dos dados da mesma forma que você pensa nas atividades.

Biblioteca dplyr

- Exemplo:
  - Quantos fumantes por sexo há na secretaria?

```
fumantes.por.sexo <- censo %>%
        filter(Fuma == 1) %>%
        group_by(Sexo) %>%
        summarise(quantidade=n())
fumantes.por.sexo
```

```
# A tibble: 4 x 2
  Sexo quantidade
 <chr>     <int>
1     F      3554
2  Fem.       186
3     M      5031
4 Masc.       878
```

Biblioteca dplyr

```
# A tibble: 4 x 2
  Sexo quantidade
 <chr>     <int>
1    F      3554
2 Fem.       186
3    M      5031
4 Masc.      878
```

- Como padronizar a coluna Sexo?
- Substituindo valores errados por valores corretos

Alterando valores errados

```
# substituir Fem. por F, e Masc. por M
# seleciona o indice das linhas que contem "Fem." e "Masc."
fem.errados <- censo$Sexo == "Fem."
masc.errados <- censo$Sexo == "Masc."
# substitui os valores pelos valores corretos, aplicando o filtro
censo[fem.errados, ]$Sexo <- "F"
censo[masc.errados, ]$Sexo <- "M"
```

Biblioteca dplyr

- Agora sim:

```
fumantes.por.sexo <- censo %>%
        filter(Fuma == 1) %>%
        group_by(Sexo) %>%
        summarise(quantidade=n())
fumantes.por.sexo
```

```
# A tibble: 2 x 2
  Sexo quantidade
  <chr>     <int>
1 F          3740
2 M          5909
```

Biblioteca dplyr

- Agora agrupando por sexo,fuma:

```
quantidade.por.sexo.fumante <- censo %>%
        group_by(Sexo, Fuma) %>%
        summarise(quantidade=n())
quantidade.por.sexo.fumante
```

Sexo	Fuma	quantidade
<chr>	<int>	<int>
1 F	0	5740
2 F	1	3740
3 M	0	4611
4 M	1	5909

Função Merge

- A função merge() serve para combinar data.frames. A função tenta identificar quais são as colunas identificadores em comum entre dois data frames para realizar a combinação. Para quem conhece SQL, a função merge() é equivalente ao join.
- Alguns argumentos da função são:
- **x**: um data.frame
  y: um data.frame
  by: a coluna em comum nos data.frames pela qual será feito o merge.
  all, **all.x**, **all.y**: especifica o tipo do merge. O default é FALSE e é equivalente ao “natural join” do SQL; “all” é equivalente ao
- “outer join”; “all.x” é equivalente ao “left outer join” e “all.y” é equivalente ao “right outer join”.

Função Merge

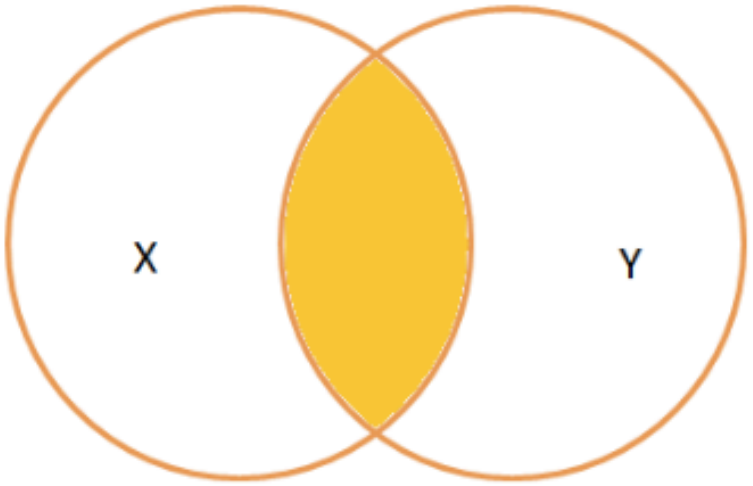

all = FALSE

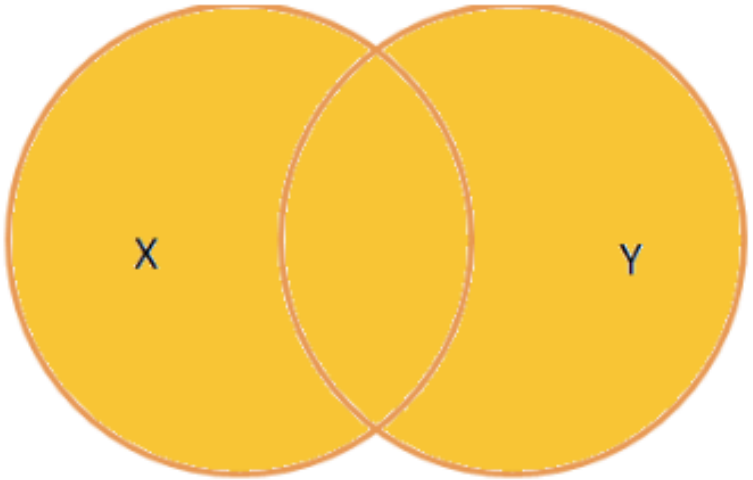

all = TRUE

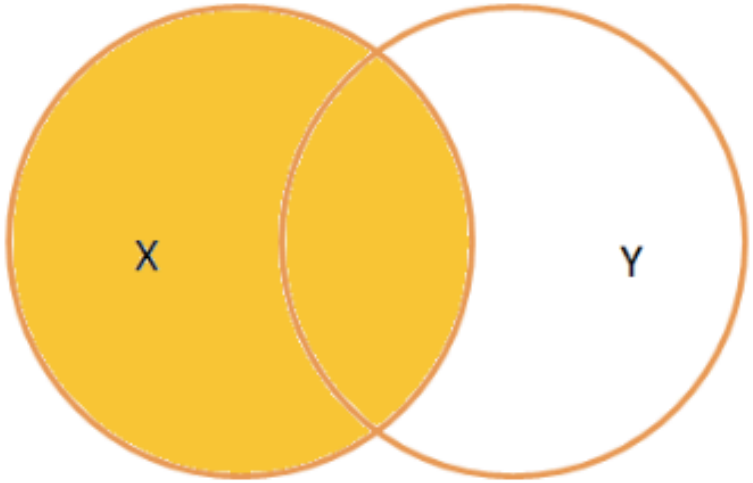

all.x = TRUE

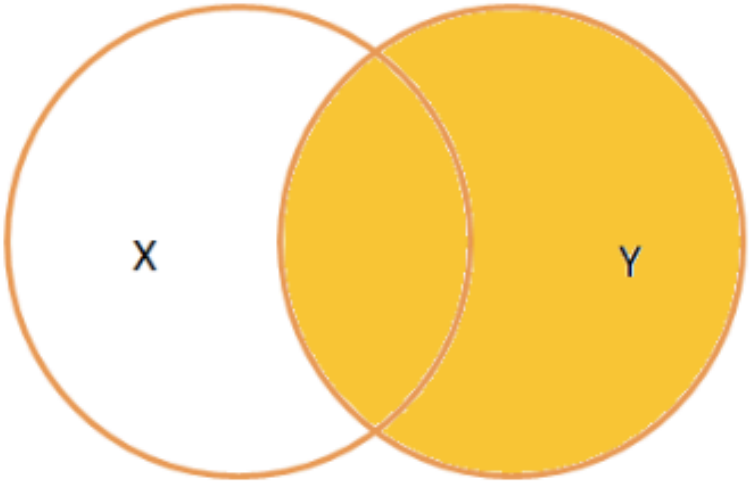

all.y = TRUE

Função Merge

- Juntar o data frame de censo com o data frame de cadastro de CPF e procurar por divergências.

- # Função merge
- censo.nome.cpf <- censo[, c("CPF", "Nome")]
- head(censo.nome.cpf)

- cadastro <- read.csv2("data/CadastroCPF.csv")
- head(cadastro)
- m <- merge(cadastro, censo.nome.cpf, by = "CPF", all.y=TRUE)
- registros.problema.identificacao <- m %>% filter(is.na(Nome.x))
- View(registros.problema.identificacao)

Qualidade de Dados com R

Qualidade de Dados com R

- Estatísticas básicas
  - Quantidade de valores únicos: função **unique()**
  - Quantidade de valores nulos: função **is.na()**
  - Valores máximos e mínimos: **summary(), max(), min()**
  - Formatos: **is.numeric(), is.charactere(), is.logical(), etc.**
  - Frequências de valores:

```
dataframe %>%
    group_by(coluna) %>%
    summarise(frequencia=n()) %>%
    arrange(desc(frequencia))
```

- Processos de melhoria
  - Função merge() para identificar CPFs e Nomes com problemas

- Não se esqueça de sempre salvar suas alteraçoes no seu repositório

Qualidade de Dados com R

- Não se esqueça de sempre salvar suas alteraçoes no seu repositório

  - git status
  - git add meuarquivo.R
  - git commit –m “mensagem”
  - git push